


# SQL Analiza



# SQL Analiza

## Agenda

1

### Funkcje okna

- **ROW\_NUMBER(), LAG(), LEAD(), FIRST\_VALUE(), LAST\_VALUE()**
- **Funkcje okna - agregaty**

2

### Wskaźniki analityczne


- YoY, MoM
- Funkcje statystyczne

3

### Podzapytania







# SQL Analiza

## Agenda

1

Funkcje okna

- ROW\_NUMBER(), LAG(), LEAD(), FIRST\_VALUE(), LAST\_VALUE()
- Funkcje okna - agregaty


2

**Wskaźniki analityczne**

- **YoY, MoM**
- **Funkcje statystyczne**

3

Podzapytania



# SQL Analiza

## Agenda

1

### Funkcje okna

- ROW\_NUMBER(), LAG(), LEAD(), FIRST\_VALUE(), LAST\_VALUE()
- Funkcje okna - agregaty

2


### Wskaźniki analityczne

- YoY, MoM
- Funkcje statystyczne

3

### Podzapytania





# SQL Analiza

Czym są funkcje okna?

infoShare  
ACADEMY

## Window Functions



### Aggregate

AVG()  
MAX()  
MIN()  
SUM()  
COUNT()


### Ranking

ROW\_NUMBER  
RANK()  
DENSE\_RANK()  
PERCENT\_RANK()  
NTILE()

### Value

ROW\_NUMBER  
RANK()  
DENSE\_RANK()  
PERCENT\_RANK()  
NTILE()





# SQL Analiza


Czym jest okno (window) w SQL?

id	release_year	rating
1	2015	8.00
2	2015	8.50
3	2015	9.00
4	2016	8.20
5	2016	8.40
6	2017	7.00



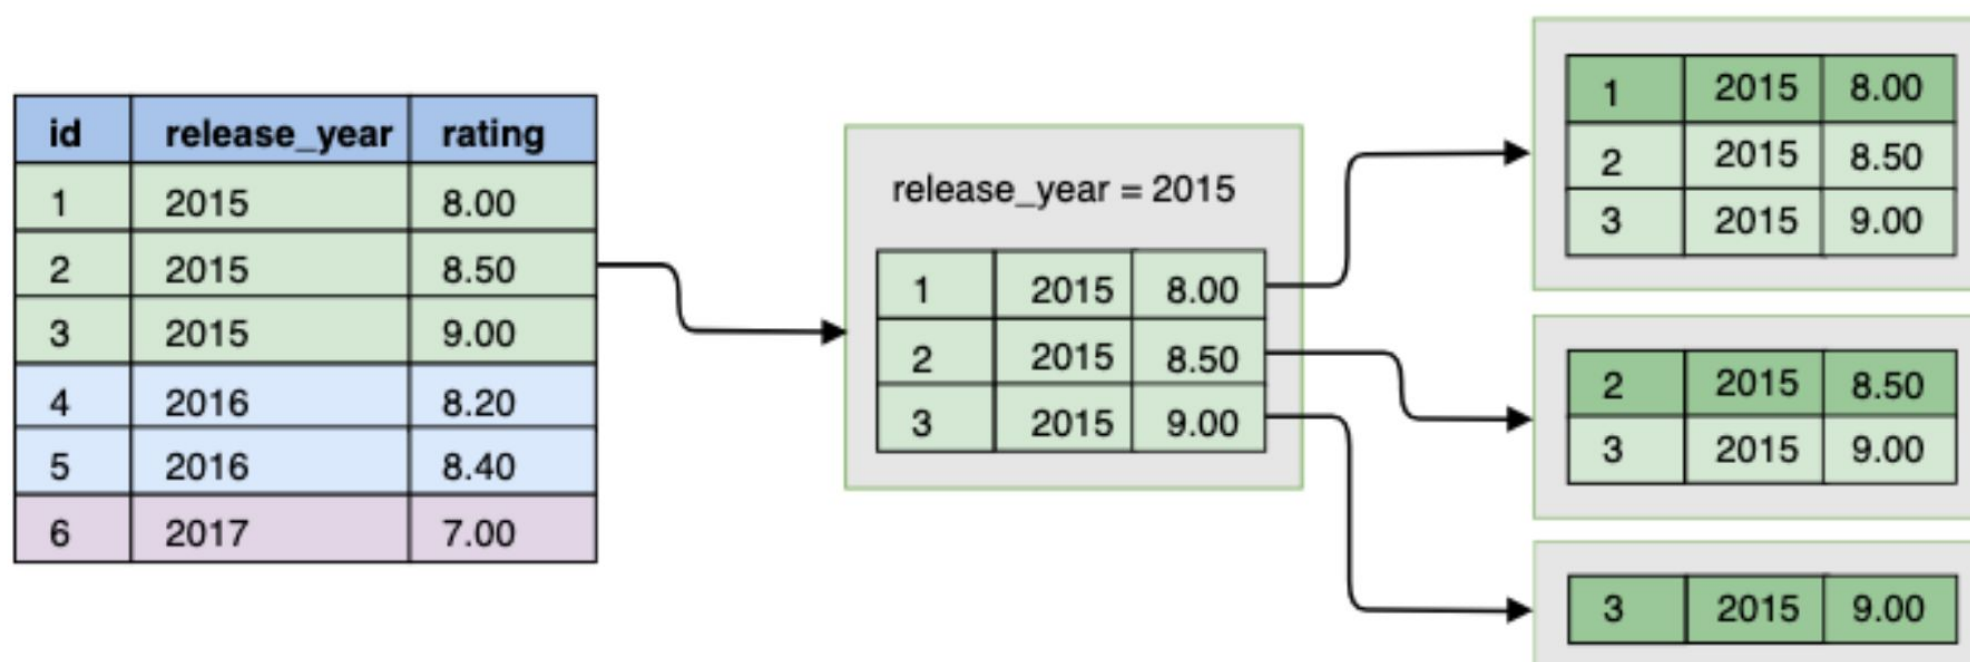
release_year = 2015		
1	2015	8.00
2	2015	8.50
3	2015	9.00

infoShare  
ACADEMY




# SQL Analiza

Czym jest ramka (window frame) w SQL?



infoShare  
ACADEMY




# SQL Analiza

## Składnia funkcji okna

```
FunkcjaOkna(argumenty) OVER (  
    [ PARTITION BY klauzula_partycjonowania ]  
    [ ORDER BY klauzula_sortowania [ ASC | DESC ] ]  
    [ NULLS { FIRST | LAST } ]  
    [ { ROWS | RANGE | GROUPS } BETWEEN początek_ramki AND koniec_ramki ]  
)
```

infoShare  
ACADEMY






# SQL Analiza

## Klauzula partycjonowania PARTITION BY


```
SELECT
    category,
    sales,
    SUM(sales) OVER (PARTITION BY category) AS total_category_sales
FROM
    sales_table;
```



# SQL Analiza

## Klauzula partycjonowania ORDER BY

```
SELECT  
    value,  
    SUM(value) OVER (ORDER BY date_column) AS cumulative_sum  
FROM  
    your_table;
```




# SQL Analiza

Klauzula ramki

```
SELECT
  column1,
  column2,
  SUM(column3) OVER (PARTITION BY partition_column ORDER BY order_column
    ROWS BETWEEN 1 PRECEDING AND 1 FOLLOWING) AS sum_with_frame
FROM
  your_table;
```





# SQL Analiza


## Utworzenie tabeli tools\_sales

-- Tworzenie tabeli

```
CREATE TABLE tools_sales (  
    sale_id SERIAL PRIMARY KEY,  
    tool_id INT,  
    tool_group VARCHAR(50),  
    sale_date DATE,  
    quantity_sold INT,  
    sale_amount DECIMAL(10, 2)  
);
```

-- Wstawianie danych

```
INSERT INTO tools_sales (tool_id, tool_group,  
sale_date, quantity_sold, sale_amount) VALUES  
    (1, 'Power Tools', '2023-01-01', 10, 500.00),  
    (2, 'Hand Tools', '2023-01-01', 5, 300.00),  
    (1, 'Power Tools', '2023-01-02', 8, 400.00),  
    (3, 'Safety Gear', '2023-01-02', 12, 600.00),  
    (2, 'Hand Tools', '2023-01-03', 7, 350.00),  
    (1, 'Power Tools', '2023-01-03', 15, 750.00);
```




# SQL Analiza

## ROW\_NUMBER()

```
SELECT
    sale_id,
    tool_id,
    tool_group,
    sale_date,
    quantity_sold,
    sale_amount,
    ROW_NUMBER() OVER (PARTITION BY tool_group ORDER BY
sale_date) AS row_num
FROM
    tools_sales
ORDER BY
    tool_group, sale_date;
```



123 sale_id	123 tool_id	ABC tool_group	🕒 sale_date	123 quantity_sold	123 sale_amount	123 row_num
2	2	Hand Tools	2023-01-01	5	300	1
5	2	Hand Tools	2023-01-03	7	350	2
1	1	Power Tools	2023-01-01	10	500	1
3	1	Power Tools	2023-01-02	8	400	2
6	1	Power Tools	2023-01-03	15	750	3
4	3	Safety Gear	2023-01-02	12	600	1




# Zadanie 3.1

## ROW\_NUMBER() (instrukcja)

Dla tabeli tools\_sales napisz kwerendę przy użyciu funkcji okienkowej ROW\_NUMBER(), która numeruje wiersze w ramach grup narzędzi (tool\_group), malejąco według kwoty sprzedaży (sale\_amount).








# SQL Analiza

## Funkcje rangi

- RANK()
- DENSE\_RANK()
- PERCENT\_RANK()






# SQL Analiza

## RANK()

```
SELECT
  sale_id,
  tool_id,
  tool_group,
  sale_date,
  quantity_sold,
  sale_amount,
  RANK() OVER (PARTITION BY tool_group ORDER BY
  quantity_sold DESC) AS rank
FROM
  tools_sales;
```



123 sale_id	123 tool_id	ABC tool_group	🕒 sale_date	123 quantity_sold	123 sale_amount	123 rank
5	2	Hand Tools	2023-01-03	7	350	1
2	2	Hand Tools	2023-01-01	5	300	2
6	1	Power Tools	2023-01-03	15	750	1
1	1	Power Tools	2023-01-01	10	500	2
3	1	Power Tools	2023-01-02	8	400	3
4	3	Safety Gear	2023-01-02	12	600	1



# SQL Analiza


## DENSE\_RANK()

```
SELECT
  sale_id,
  tool_id,
  tool_group,
  sale_date,
  quantity_sold,
  sale_amount,
  DENSE_RANK() OVER (PARTITION BY tool_group ORDER BY
quantity_sold DESC) AS dense_rank
FROM
  tools_sales;
```



sale_id	tool_id	tool_group	sale_date	quantity_sold	sale_amount	dense_rank
5	2	Hand Tools	2023-01-03	7	350	1
2	2	Hand Tools	2023-01-01	5	300	2
6	1	Power Tools	2023-01-03	15	750	1
1	1	Power Tools	2023-01-01	10	500	2
3	1	Power Tools	2023-01-02	8	400	3
4	3	Safety Gear	2023-01-02	12	600	1






# SQL Analiza

## PERCENT\_RANK()

```
SELECT
  sale_id,
  tool_id,
  tool_group,
  sale_date,
  quantity_sold,
  sale_amount,
  PERCENT_RANK() OVER (PARTITION BY tool_group ORDER BY
  quantity_sold DESC) AS percent_rank
FROM
  tools_sales;
```



123 sale_id	123 tool_id	ABC tool_group	sale_date	123 quantity_sold	123 sale_amount	123 percent_rank
5	2	Hand Tools	2023-01-03	7	350	0
2	2	Hand Tools	2023-01-01	5	300	1
6	1	Power Tools	2023-01-03	15	750	0
1	1	Power Tools	2023-01-01	10	500	0.5
3	1	Power Tools	2023-01-02	8	400	1
4	3	Safety Gear	2023-01-02	12	600	0




## Zadanie 3.2

### RANK() (instrukcja)

Dla tabeli tools\_sales przypisz rangi dla rekordów w tabeli w oparciu o rosnącą datę sprzedaży (sale\_date). Potraktuj rekordy jako jedną grupę.





# SQL Analiza


## CUME\_DIST()

```
SELECT
  tool_id,
  tool_group,
  sale_amount,
  CUME_DIST() OVER (ORDER BY sale_amount) AS
  cumulative_distribution
FROM
  tools_sales;
```



123 tool_id	ABC tool_group	123 sale_amount	123 cumulative_distribution
2	Hand Tools	300	0.166666667
2	Hand Tools	350	0.333333333
1	Power Tools	400	0.5
1	Power Tools	500	0.666666667
3	Safety Gear	600	0.833333333
1	Power Tools	750	1






# SQL Analiza

## NTILE()

```
SELECT
    tool_id,
    tool_group,
    sale_amount,
    NTILE(4) OVER (ORDER BY sale_amount) AS quartile
FROM
    tools_sales;
```



123 tool_id	ABC tool_group	123 sale_amount	123 quartile
2	Hand Tools	300	1
2	Hand Tools	350	1
1	Power Tools	400	2
1	Power Tools	500	2
3	Safety Gear	600	3
1	Power Tools	750	4




## Zadanie 3.3

### NTILE() (instrukcja)

Dla tabeli tools\_sales podziel rekordy na trzy grupy (kwantyle) w obrębie każdej grupy narzędziowej (tool\_group) uszeregowanej według rosnącej kwoty sprzedaży.





# SQL Analiza

**LAG(), LEAD()**

**LEAD(expression, offset, default)**

**LAG(expression, offset, default)**



wyrażenie




liczba wierszy  
wstecz/do przodu



wartość  
domyślna,  
gdy brak  
poprzedniego/  
następnego  
wiersza

**infoShare**  
ACADEMY






# SQL Analiza

## LAG()

```
SELECT
  sale_id,
  tool_id,
  sale_date,
  quantity_sold,
  LAG(quantity_sold, 1, 0) OVER (ORDER BY sale_date) AS
  prev_quantity
FROM
  tools_sales
ORDER BY
  sale_date;
```



sale_id	tool_id	sale_date	quantity_sold	prev_quantity
1	1	2023-01-01	10	0
2	2	2023-01-01	5	10
3	1	2023-01-02	8	5
4	3	2023-01-02	12	8
5	2	2023-01-03	7	12
6	1	2023-01-03	15	7




# SQL Analiza

## LEAD()

```
SELECT
  sale_id,
  tool_id,
  sale_date,
  quantity_sold,
  LEAD(quantity_sold, 1, 0) OVER (ORDER BY sale_date) AS next_quantity
FROM
  tools_sales
ORDER BY
  sale_date;
```

123 sale_id	123 tool_id	🕒 sale_date	123 quantity_sold	123 prev_quantity
1	1	2023-01-01	10	5
2	2	2023-01-01	5	8
3	1	2023-01-02	8	12
4	3	2023-01-02	12	7
5	2	2023-01-03	7	15
6	1	2023-01-03	15	0




# Zadanie 3.4

## LAG() / LEAD() (instrukcja)

Dla tabeli tools\_sales napisz zapytanie, które zawierać będzie informacje o:

- grupie narzędzi,
- dacie sprzedaży,
- ilości sprzedanych sztuk,
- ilości sprzedanych sztuk dla poprzedniej i następnej daty sprzedaży w obrębie tej samej grupy narzędzi.






# SQL Analiza

**FIRST\_VALUE(), LAST\_VALUE(), NTH\_VALUE()**

FIRST\_VALUE(column)

LAST\_VALUE(column)

NTH\_VALUE(column, n), gdzie n to określona pozycja




# SQL Analiza

## FIRST\_VALUE()

```
SELECT
    tool_group,
    sale_date,
    quantity_sold,
    FIRST_VALUE(quantity_sold) OVER (PARTITION BY tool_group
ORDER BY sale_date) AS first_quantity
FROM
    tools_sales;
```



ABC tool_group ▼	🕒 sale_date ▼	123 quantity_sold ▼	123 first_quantity ▼
Hand Tools	2023-01-01	5	5
Hand Tools	2023-01-03	7	5
Power Tools	2023-01-01	10	10
Power Tools	2023-01-02	8	10
Power Tools	2023-01-03	15	10
Safety Gear	2023-01-02	12	12



# SQL Analiza


## LAST\_VALUE()

```
SELECT
  tool_group,
  sale_date,
  quantity_sold,
  LAST_VALUE(quantity_sold) OVER (PARTITION BY tool_group
ORDER BY sale_date) AS first_quantity
FROM
  tools_sales;
```



ABC tool_group ▼	🕒 sale_date ▼	123 quantity_sold ▼	123 first_quantity ▼
Hand Tools	2023-01-01	5	5
Hand Tools	2023-01-03	7	7
Power Tools	2023-01-01	10	10
Power Tools	2023-01-02	8	8
Power Tools	2023-01-03	15	15
Safety Gear	2023-01-02	12	12






# SQL Analiza

## NTH\_VALUE()

```
SELECT
    tool_group,
    sale_date,
    quantity_sold,
    NTH_VALUE(quantity_sold, 3) OVER (PARTITION BY tool_group ORDER BY
    sale_date) AS first_quantity
FROM
    tools_sales;
```



ABC tool_group ▼	🕒 sale_date ▼	123 quantity_sold ▼	123 first_quantity ▼
Hand Tools	2023-01-01	5	[NULL]
Hand Tools	2023-01-03	7	[NULL]
Power Tools	2023-01-01	10	[NULL]
Power Tools	2023-01-02	8	[NULL]
Power Tools	2023-01-03	15	15
Safety Gear	2023-01-02	12	[NULL]




# Zadanie 3.5

## FIRST/LAST/NTH\_VALUE (instrukcja)

Dla tabeli all\_seasons o koszykarzach NBA znajdź pierwszy i ostatni sezon dla każdego koszykarza.





# SQL Analiza

Agregaty **avg()**, **sum()**, **count()**, **min()**, **max()**

**AVG**(sale\_amount) OVER (PARTITION BY tool\_group ORDER BY sale\_date)


**SUM**(quantity\_sold) OVER (PARTITION BY tool\_group ORDER BY sale\_date)

**COUNT**(\*) OVER (PARTITION BY tool\_group ORDER BY sale\_date)

**MIN**(sale\_amount) OVER (PARTITION BY tool\_group ORDER BY sale\_date)

**MAX**(quantity\_sold) OVER (PARTITION BY tool\_group ORDER BY sale\_date)






# SQL Analiza

## AVG()

```
SELECT
    tool_group,
    sale_date,
    quantity_sold,
    AVG(quantity_sold) OVER (PARTITION BY tool_group ORDER BY sale_date)
AS avg_quantity
FROM
    tools_sales;
```



ABC tool_group ▼	🕒 sale_date ▼	123 quantity_sold ▼	123 avg_quantity ▼
Hand Tools	2023-01-01	5	5
Hand Tools	2023-01-03	7	6
Power Tools	2023-01-01	10	10
Power Tools	2023-01-02	8	9
Power Tools	2023-01-03	15	11
Safety Gear	2023-01-02	12	12



# SQL Analiza


## SUM()

```
SELECT
    tool_group,
    sale_date,
    quantity_sold,
    SUM(quantity_sold) OVER (PARTITION BY tool_group ORDER BY sale_date)
AS total_quantity
FROM
    tools_sales;
```



ABC tool_group ▼	🕒 sale_date ▼	123 quantity_sold ▼	123 total_quantity ▼
Hand Tools	2023-01-01	5	5
Hand Tools	2023-01-03	7	12
Power Tools	2023-01-01	10	10
Power Tools	2023-01-02	8	18
Power Tools	2023-01-03	15	33
Safety Gear	2023-01-02	12	12





# SQL Analiza


## COUNT()

```
SELECT
    tool_group,
    sale_date,
    COUNT(*) OVER (PARTITION BY tool_group) AS days_with_sales
FROM
    tools_sales;
```



ABC tool_group ▼	🕒 sale_date ▼	123 days_with_sales ▼
Hand Tools	2023-01-01	2
Hand Tools	2023-01-03	2
Power Tools	2023-01-01	3
Power Tools	2023-01-02	3
Power Tools	2023-01-03	3
Safety Gear	2023-01-02	1






# SQL Analiza

## MIN() MAX()

```
SELECT
    tool_group,
    sale_date,
    quantity_sold,
    MIN(quantity_sold) OVER (PARTITION BY tool_group) AS min_quantity_sold,
    MAX(quantity_sold) OVER (PARTITION BY tool_group) AS max_quantity_sold
FROM
    tools_sales;
```



ABC tool_group ▼	🕒 sale_date ▼	123 quantity_sold ▼	123 min_quantity_sold ▼	123 max_quantity_sold ▼
Hand Tools	2023-01-01	5	5	7
Hand Tools	2023-01-03	7	5	7
Power Tools	2023-01-01	10	8	15
Power Tools	2023-01-02	8	8	15
Power Tools	2023-01-03	15	8	15
Safety Gear	2023-01-02	12	12	12




# Zadanie 3.6

## Agregaty (instrukcja)



Dla zbioru danych tools\_sales znajdź:

- sumę i średnią wartość sprzedaży dla każdej grupy narzędzi, posortowanych według daty sprzedaży,
- maksymalną wartość sprzedaży dla każdej grupy narzędzi, posortowanych według daty sprzedaży,
- najwcześniejszą datę sprzedaży dla każdej grupy narzędzi.




# SQL Analiza

## Funkcje okna – podsumowanie



1. ROW\_NUMBER(), RANK(), DENSE\_RANK()
2. FIRST\_VALUE(), LAST\_VALUE(), NTH\_VALUE()
3. LAG(), LEAD()
4. CUME\_DIST()
5. NTILE()
6. AVG(), SUM(), COUNT(), MIN(), MAX()





# Zadanie 3.7

## Podsumowanie (instrukcja)


Analiza Sprzedaży Narzędzi – masz do dyspozycji tabelę `tools_sales` z informacjami o sprzedaży narzędzi w sklepie. Twoim zadaniem jest przygotowanie analizy danych przy użyciu funkcji okienkowych.

**a. Numeracja Zamówień:** Dodaj kolumnę `order_number`, w której przypiszesz unikalne numery porządkowe dla każdego zamówienia, sortując je według daty sprzedaży.

**b. Rangi Grup Narzędziowych:** Nadaj rangi dla każdej grupy narzędziowej, zaczynając od jedynki, sortując według ilości sprzedanych narzędzi malejąco.

**c. Kumulatywny Rozkład Sprzedaży:** Utwórz kolumnę `cumulative_sales`, która będzie zawierać kumulatywną sumę sprzedaży dla każdego narzędzia, uporządkowanego według daty sprzedaży.

**d. Analiza Dynamiki Sprzedaży:** Stwórz kolumny `sales_change` i `percentage_change`, które pokażą zmiany w ilości sprzedanych narzędzi i procentową zmianę w stosunku do poprzedniego zamówienia.




# SQL Analiza

## Funkcje statystyczne

- **YoY**
- **MoM**





# SQL Analiza

## YoY

- Year over Year – procentowa zmiana w stosunku do poprzedniego roku


$$\text{YoY \%} = \frac{\text{aktualny rok} - \text{poprzedni rok}}{\text{poprzedni rok}}$$

```
SELECT
  Year,
  Sales,
  LAG(Sales, 1) OVER (ORDER BY Year) AS SalesLastYear,
  ((Sales - LAG(Sales, 1) OVER (ORDER BY Year)) / LAG(Sales, 1)
  OVER (ORDER BY Year)) * 100 AS YoYChange
FROM
  SalesData;
```



123 year ▼	123 sales ▼	123 saleslastyear ▼	123 yoychange ▼
2,019	120,000	[NULL]	[NULL]
2,020	150,000	120,000	25
2,021	180,000	150,000	20
2,022	200,000	180,000	11.1111111111





# SQL Analiza

## MoM


- Month over Month – procentowa zmiana w stosunku do poprzedniego miesiące

$$\text{MoM \%} = \frac{\text{aktualny miesiąc} - \text{poprzedni miesiąc}}{\text{poprzedni miesiąc}}$$

```
SELECT
    Month,
    Sales,
    LAG(Sales, 1) OVER (ORDER BY Month) AS SalesLastMonth,
    ((Sales - LAG(Sales, 1) OVER (ORDER BY Month)) / LAG(Sales, 1)
    OVER (ORDER BY Month)) * 100 AS MoMChange
FROM
    SalesData;
```




month	123 sales	123 saleslastmonth	123 momchange
2023-01-01	120,000	[NULL]	[NULL]
2023-02-01	130,000	120,000	8.3333333333
2023-03-01	150,000	130,000	15.3846153846
2023-04-01	140,000	150,000	-6.6666666667
2023-05-01	160,000	140,000	14.2857142857



# Zadanie 3.8

## YoY / MoM (instrukcja)

Dla tabeli all\_seasons o koszykarzach NBA znajdź średnią liczbę zdobytych punktów w sezonie dla każdego koszykarza oraz oblicz procentową zmianę średnich punktów rok do roku (YoY).




# SQL Analiza

## Funkcje statystyczne

- Mode()
- Percenitle\_disc()
- Percentile\_cont()







# SQL Analiza

## Kwantyle / percentile

infoShare  
ACADEMY

- **Kwantyl** rzędu  $p$  to wartość liczbowa ze zbioru, od której  $p$ -ta część zbioru jest mniejsza.
- **Percentyle** – kwantyle rzędów  $x/100$  – podział rosnąco posortowanego zbioru na 100 części.






# SQL Analiza

## Kwantyle

- Kwantyle – kwantyle rzędów  $x/4$  – podział rosnąco posortowanego zbioru na 4 części.
- Kwartyl Q2 to mediana, wartość środkowa.





# SQL Analiza

## Moda

- Moda, dominanta – wartość najczęstsza.



100 zł


120 zł

120 zł

120 zł

180 zł






# SQL Analiza

## MODE()

```
SELECT tool_group, MODE() WITHIN GROUP (ORDER BY  
quantity_sold) AS mode_quantity  
FROM tools_sales  
GROUP BY tool_group;
```



ABC tool_group ▼	123 mode_quantity ▼
Hand Tools	5
Power Tools	8
Safety Gear	12




# SQL Analiza

## PERCENTILE\_DISC()

```
SELECT tool_group, PERCENTILE_DISC(0.5) WITHIN GROUP (ORDER BY  
quantity_sold) AS median_quantity  
FROM tools_sales  
GROUP BY tool_group;
```



ABC tool_group ▼	123 median_quantity ▼
Hand Tools	5
Power Tools	10
Safety Gear	12



# SQL Analiza


## PERCENTILE\_CONT()

```
SELECT tool_group, PERCENTILE_CONT(0.5) WITHIN GROUP (ORDER BY  
quantity_sold) AS median_quantity  
FROM tools_sales  
GROUP BY tool_group;
```



ABC tool_group ▼	123 median_quantity ▼
Hand Tools	6
Power Tools	10
Safety Gear	12






# Zadanie 3.9

## Funkcje statystyczne (instrukcja)

Dla zbioru `tools_sales` oblicz ile wynosi:

- najczęściej występująca data sprzedaży dla każdej grupy narzędzi,
- mediana kwoty sprzedaży dla każdej grupy narzędzi (użyj zarówno funkcji `percentile_disc` jak i `percentile_cont` i porównaj wyniki).






# SQL Analiza

## Funkcje statystyczne – c.d.

- Wariancja
- Odchylenie standardowe
- Korelacja








# SQL Analiza

## Wariancja i odchylenie standardowe


infoShare  
ACADEMY

Wariancja (VAR) i odchylenie standardowe (STDDEV) to typowe miary rozrzutu danych. Można je policzyć dla całej populacji jak i dla próbki.

STDDEV to po prostu pierwiastek kwadratowy z wariancji. Odchylenie std jest wyrażone w oryginalnych jednostkach, natomiast VAR w jednostkach do kwadratu.



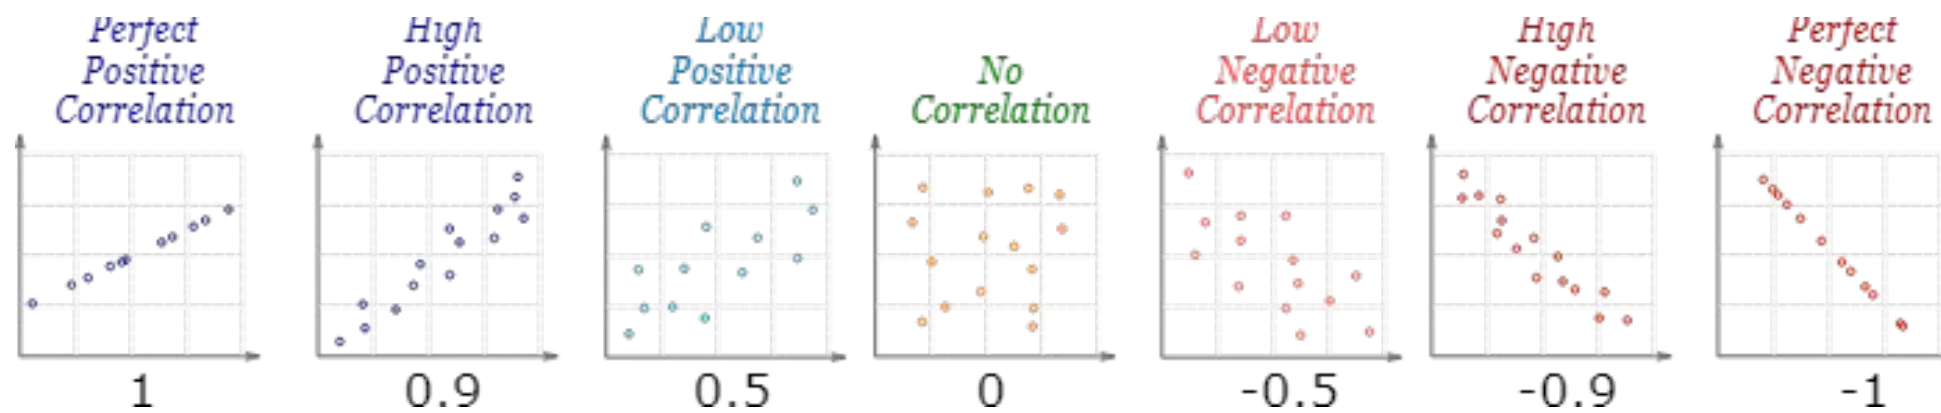





# SQL Analiza

## Korelacja

infoShare  
ACADEMY





# SQL Analiza

## Kowariancja

- Liczba określająca odchylenie elementów od sytuacji idealnej, w której występuje zależność liniowa.
- W przypadku braku korelacji liniowej, kowariancja przyjmuje wartość 0.
- Zależność pomiędzy kowariancją a korelacją:


$$\mathbf{cov(X,Y) = corr(X,Y)\delta_x\delta_y}$$

gdzie:

**corr(X,Y)** – współczynnik korelacji liniowej pomiędzy zmiennymi X i Y

**$\delta_x$**  – odchylenie standardowe zmiennej X

**$\delta_y$**  – odchylenie standardowe zmiennej Y




# SQL Analiza

## Funkcje statystyczne agregujące

- `corr(dependent, independent)`
- `covar_pop()` / `covar_samp()`
- `stddev_pop()` / `stddev_samp()` / `stddev()`
- `var_pop()` / `var_samp()` / `variance()`
- \* `regr_intercept()`
- \* `regr_slope()`








# SQL Analiza

## STDDEV()

```
SELECT
    tool_group,
    STDDEV(quantity_sold) AS std_dev_quantity
FROM
    tools_sales
GROUP BY
    tool_group;
```



ABC tool_group ▼	123 std_dev_quantity ▼
Hand Tools	1.4142135624
Safety Gear	[NULL]
Power Tools	3.6055512755




# SQL Analiza

## CORR()

```
SELECT  
    CORR(quantity_sold, sale_amount) AS correlation  
FROM  
    tools_sales;
```

123 correlation
0.9954182273






# Zadanie 3.10

## Funkcje statystyczne (instrukcja)

Dla tabeli `tools_sales` oblicz wariancję ilości sprzedanych sztuk narzędzi.








# SQL Analiza

## Funkcje statystyczne – c.d.

- YoY, MoM
- Mode()
- Percenitle\_disc()
- Percentile\_cont()
- Wariancja
- Odchylenie standardowe
- Korelacja




# Zadanie 3.11

Podsumowanie funkcji statystycznych  
(instrukcja)

Przy użyciu tabeli `all_seasons`, która zawiera dane o koszykarzach NBA, wykonaj następujące analizy:

- Oblicz średnią liczbę punktów (`pts`) dla każdego sezonu.
- Oblicz medianę wzrostu (`player_height`) dla wszystkich graczy.
- Oblicz korelację między liczbą punktów (`pts`) a liczbą asyst (`ast`).
- Znajdź najczęściej występującą rundę draftu (`draft_round`).

infoShare  
ACADEMY




# SQL Analiza

## Podzapytania

- Podzapytanie pozwala na wykorzystanie w ramach języka DQL (SELECT) kolejnego zapytania SELECT.
- Na ogół podzapytanie można wykonać jako poznany już JOIN.
- W większości przypadków wydajność JOIN jak i podzapytania są zbliżone.
- Czasem jednak jedna forma pozwala skrócić kod lub jest szybsza do napisania.






# SQL Analiza

## Podzapytania – występowanie

- SELECT
- FROM
- WHERE
- ORDER BY
- LIMIT
- HAVING





# SQL Analiza

## Podzapytania w klauzuli SELECT




1. Pobieranie jednej wartości

```
SELECT column1, (SELECT MAX(column2) FROM table2) AS max_value  
FROM table1;
```

2. Pobieranie więcej niż jednej kolumny

```
SELECT column1, column2 ,  
(SELECT column3, column4 FROM table2 WHERE condition) AS  
subquery_result  
FROM table1;
```



# SQL Analiza

## Podzapytania w klauzuli FROM

1. Podzapytanie jako źródło danych

```
SELECT column1, column2
```

```
FROM (SELECT * FROM table1 WHERE condition) AS subquery;
```

2. Łączenie wielu źródeł danych

```
SELECT column1, column2
```

```
FROM table1
```

```
JOIN (SELECT * FROM table2 WHERE condition) AS subquery
```


```
ON table1.columnX = subquery.columnY;
```

3. Podzapytania zwracające więcej niż jedną kolumnę

```
SELECT column1, column2
```

```
FROM (SELECT columnX, columnY FROM table2 WHERE condition) AS  
subquery;
```





# SQL Analiza

## Podzapytania w klauzuli WHERE

1. Porównanie z pojedynczym wynikiem

```
SELECT column1, column2
```

```
FROM table1
```

```
WHERE columnX = (SELECT columnY FROM table2 WHERE condition);
```

2. Porównanie z wynikami podzapytania

```
SELECT column1, column2
```

```
FROM table1
```


```
WHERE columnX IN (SELECT columnY FROM table2 WHERE condition);
```

3. Użycie podzapytania w warunku logicznym

```
SELECT column1, column2
```

```
FROM table1
```

```
WHERE EXISTS (SELECT 1 FROM table2 WHERE condition);
```




# Zadanie 3.12

## Instrukcja

Dla tabeli all\_seasons:

- Wybierz wszystkich koszykarzy z sezonu 2020/2021, którzy zdobyli więcej punktów niż średnia liczba punktów zdobytych przez wszystkich koszykarzy w sezonie 2019/2020.





# SQL Analiza

## Podzapytania w klauzuli ORDER BY

1. Sortowanie wyników zapytania za pomocą podzapytania

```
SELECT column1, column2  
FROM table  
ORDER BY (SELECT some_column FROM another_table WHERE condition)  
DESC;
```


2. Sortowanie po wynikach innego zapytania

```
SELECT column1, column2  
FROM table1  
ORDER BY (SELECT AVG(some_column) FROM table2) DESC;
```

3. Sortowanie warunkowe z podzapytaniem

```
SELECT column1, column2  
FROM table  
ORDER BY CASE WHEN (SELECT COUNT(*) FROM another_table  
WHERE condition) > 0 THEN column1 ELSE column2 END DESC;
```





# SQL Analiza

## Podzapytania w klauzuli LIMIT


1. Dynamiczne ustawianie LIMIT z podzapytaniem

SELECT column1, column2

FROM table

LIMIT (**SELECT COUNT(\*) FROM another\_table WHERE condition**);





# SQL Analiza

## Podzapytania w klauzuli HAVING

1. Grupowanie po kolumnie i filtrowanie wyników z użyciem HAVING

```
SELECT category, AVG(price) AS average_price
```

```
FROM products
```

```
GROUP BY category
```

```
HAVING AVG(price) > (SELECT AVG(price) FROM products);
```

2. Podzapytanie w HAVING z Warunkiem IN


```
SELECT category, COUNT(*) AS product_count
```

```
FROM products
```

```
GROUP BY category
```

```
HAVING COUNT(*) IN (SELECT MAX(product_count) FROM  
products_by_category);
```






# Zadanie 3.13

## Instrukcja

Dla tabeli all\_seasons o koszykarzach NBA wybierz drużyny, które mają średnią liczbę punktów większą niż globalna średnia.






# SQL Analiza

## Podzapytania podsumowanie


- 1** Unikaj nadmiernego użycia podzapytań.
- 2** Staraj się, aby podzapytania były czytelne.
- 3** Zwracaj uwagę na wydajność.
- 4** Unikaj zbyt dużych zagnieżdżeń.
- 5** Testuj i analizuj wyniki.
- 6** Zwracaj uwagę na indeksy.



# SQL Analiza

## Podzapytania podsumowanie

- 1 Unikaj nadmiernego użycia podzapytań.
- 2 **Staraj się, aby podzapytania były czytelne.**
- 3 Zwracaj uwagę na wydajność.
- 4 Unikaj zbyt dużych zagnieżdżeń.
- 5 Testuj i analizuj wyniki.
- 6 Zwracaj uwagę na indeksy.




# SQL Analiza

## Podzapytania podsumowanie

- 1 Unikaj nadmiernego użycia podzapytań.
- 2 Staraj się, aby podzapytania były czytelne.
- 3 **Zwracaj uwagę na wydajność.**
- 4 Unikaj zbyt dużych zagnieżdżeń.
- 5 Testuj i analizuj wyniki.
- 6 Zwracaj uwagę na indeksy.






# SQL Analiza

## Podzapytania podsumowanie


- 1 Unikaj nadmiernego użycia podzapytań.
- 2 Staraj się, aby podzapytania były czytelne.
- 3 Zwracaj uwagę na wydajność.
- 4 **Unikaj zbyt dużych zagnieżdżeń.**
- 5 Testuj i analizuj wyniki.
- 6 Zwracaj uwagę na indeksy.



# SQL Analiza

## Podzapytania podsumowanie

- 1 Unikaj nadmiernego użycia podzapytań.
- 2 Staraj się, aby podzapytania były czytelne.
- 3 Zwracaj uwagę na wydajność.
- 4 Unikaj zbyt dużych zagnieżdżeń.
- 5 **Testuj i analizuj wyniki.**
- 6 Zwracaj uwagę na indeksy.




# SQL Analiza

## Podzapytania podsumowanie

- 1 Unikaj nadmiernego użycia podzapytań.
- 2 Staraj się, aby podzapytania były czytelne.
- 3 Zwracaj uwagę na wydajność.
- 4 Unikaj zbyt dużych zagnieżdżeń.
- 5 Testuj i analizuj wyniki.
- 6 **Zwracaj uwagę na indeksy.**



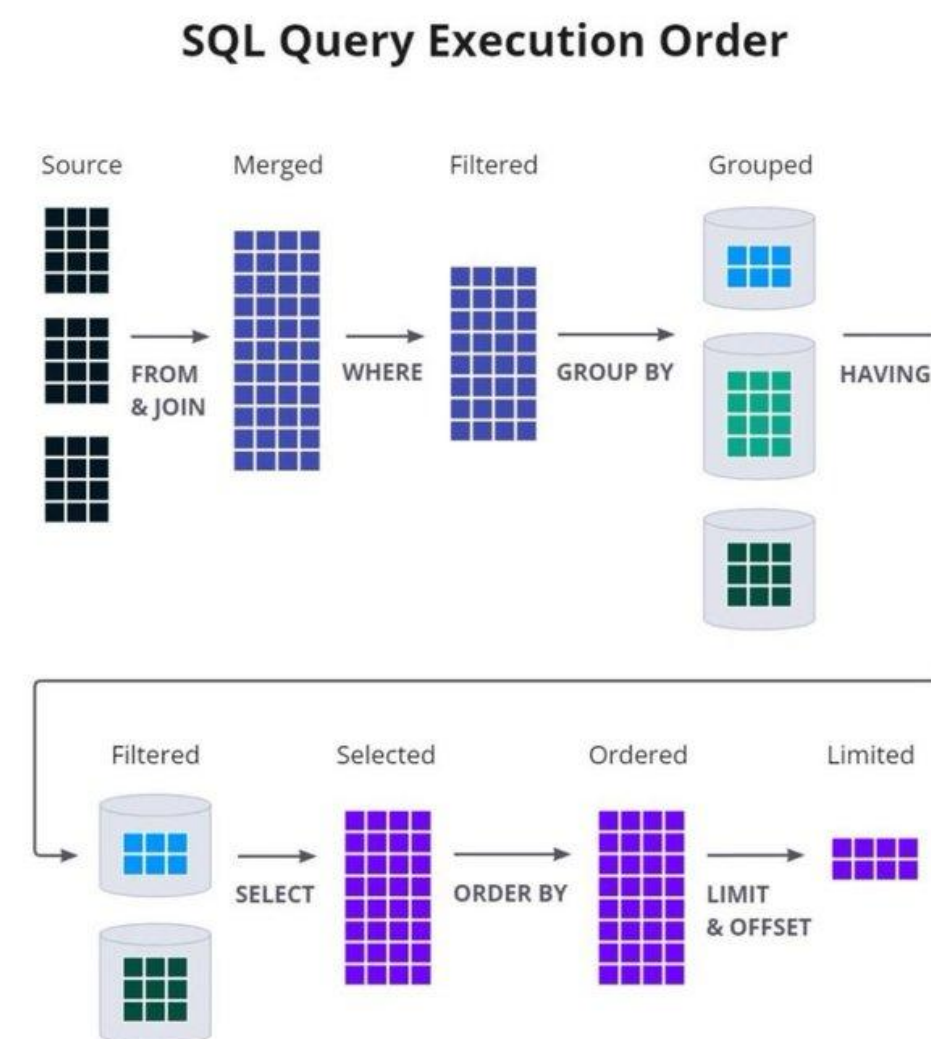



# SQL Analiza

## Podzapytania podsumowanie



- SELECT
- FROM
- WHERE
- ORDER BY
- LIMIT
- HAVING






# Zadanie 3.14

## Podsumowujące (instrukcja)

Dla tabeli all\_seasons o koszykarzach NBA oblicz:

- Jaka drużyna ma średnią liczbę punktów mniejszą niż drużyny z największą liczbą zwycięstw.
- Ile wynosi różnica pomiędzy średnią liczbą punktów a średnią liczbą zbiórek dla każdego gracza.





# SQL Analiza

Podsumowanie



infoShare  
ACADEMY